

Gradiente Conjugado

+ Método Iterativo para resolver
el sistema lineal $Ax = b$

+ $\min_x \phi(x) = \frac{1}{2} x^T A x - b^T x$

1950. \Downarrow Eliminación Gaussiana.

$$\nabla \phi(x) = Ax - b = r(x) \rightarrow \text{residuo del sistema.}$$

$$x_k \Rightarrow Ax_k - b = r_k$$

Métodos de direcciones conjugadas

• Basato $\{p_0, p_1, \dots\}$ son conjugados

con respecto a la matriz A-simétrica pos. def.

Un par de vectores p_i, p_j son conjugados con respecto

a A

$$p_i^T A p_j = 0 \quad i \neq j.$$

$\Rightarrow \{p_0, \dots, p_{n-1}\}$ es un conjunto linealmente independiente

Dado un $x_0 \in \mathbb{R}^n$ y un conjunto de direcciones conjugadas

$$\{p_0, \dots, p_{n-1}\}$$

$$x_{k+1} = x_k + \alpha_k p_k \quad \text{donde elegimos } \alpha_k$$

\rightarrow minimice $\phi(x)$ sobre la linea $x_k + \alpha p_k$.

$$\hat{\phi}(\alpha) = \phi(x_k + \alpha p_k)$$

$$\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k}$$

15

Teorema.

Para cualquier $x_0 \in \mathbb{R}^n$ la secuencia generada por el algoritmo (1) converge a la solución x^* del sistema lineal $Ax=b$ en a lo más n pasos.

Demostración.

$\{P_i\}$ es linearmente independiente. $\Rightarrow \text{Span}\{\{P_i\}\} = \mathbb{R}^n$

$$\Rightarrow x^* - x_0 = \alpha_0 P_0 + \dots + \alpha_{n-1} P_{n-1}$$

Premultiplicamos por ... $P_k^T A$.

$$\alpha_k = \frac{P_k^T A (x^* - x_0)}{P_k^T A P_k}$$

Si $\{x_i\}$ es generado por (1)

Tenemos que:

$$x_k = x_0 + \alpha_0 P_0 + \dots + \alpha_{k-1} P_{k-1}$$

$$\Rightarrow P_k^T A (x_k - x_0) = 0 \Rightarrow P_k^T A (x^* - x_0 + x_k - x^*) = 0.$$

$$\begin{aligned} \Rightarrow P_k^T A (x^* - x_0) &= P_k^T A (x^* - x_k) \\ &= P_k^T (b - Ax_k) \end{aligned}$$

$$= -P_k^T r_k$$

$$\Rightarrow \alpha_k = \alpha_k$$



$$r_{k+1} = r_k + \alpha_k A p_k$$

Teorema:

Sea $x_0 \in \mathbb{R}^n$ sea cualquier punto inicial y supongamos que tenemos la secuencia $\{x_i\}$ generada por (1). Entonces:

$$r_k^T p_i = 0 \text{ para } i=0, \dots, k-1$$

y x_k es el minimizador de $\phi(x) = \frac{1}{2} x^T A x - b^T x$ sobre el subespacio:

$$\left\{ x \mid x = x_0 + \text{Span}\{p_0, \dots, p_{k-1}\} \right\} \xrightarrow{(1)} \textcircled{0}$$

Demonstración:

\tilde{x} minimiza ϕ sobre (1) $\Leftrightarrow r(\tilde{x})^T p_i = 0$ para cada $i=0, \dots, k-1$

$$h(\sigma) = \phi(x_0 + \sigma_0 p_0 + \dots + \sigma_{k-1} p_{k-1}), \text{ donde } \sigma = \begin{pmatrix} \sigma_0 \\ \vdots \\ \sigma_{k-1} \end{pmatrix}$$

h es cuadrática convexa. σ^*

$$\frac{\partial h(\sigma^*)}{\partial \sigma_i} = 0 \quad i=0, \dots, k-1.$$

$$\nabla \phi(x_0 + \dots + \sigma_{k-1}^* p_{k-1})^T p_i = 0 \quad \forall i=0, \dots, k-1.$$

$\xrightarrow{r(\tilde{x})}$

$$\tilde{x} = x_0 + \sigma_0^* p_0 + \dots + \sigma_{k-1}^* p_{k-1}$$

$$\Rightarrow r(\tilde{x})^T p_i = 0 \quad \forall i=0, \dots, k-1$$

P.D. x_k cumple $r_k^T p_i = 0$.

Inducción:

$$k=1 \quad x_1 = x_0 + \underline{\alpha_0 p_0} \quad \text{minimiza } \phi \text{ sobre la dirección } p_0$$

$$\cancel{r_1^T p_0 = 0}$$

Hipótesis de inducción:

$$r_{k+1}^T p_i = 0 \quad i=0, 1, \dots, k-2, \quad r_k = r_{k+1} + \alpha_{k+1} A p_{k+1} *$$

$$\Rightarrow P_{k+1}^T r_k = P_{k+1}^T r_{k+1} + \alpha_{k+1} \xrightarrow{-r_{k+1}^T p_{k+1}} \xrightarrow{P_{k+1}^T A P_{k+1}} \\ = 0. = P_{k+1}^T r_{k+1} - P_{k+1}^T r_{k+1}$$

$$P_i, i=0, \dots, k-2 \quad P_i^T r_k = P_i^T r_{k+1} + \alpha_{k+1} P_i^T A P_{k+1} = 0 \quad \xrightarrow{\text{inducción}} \text{conjugado:} \\ \Rightarrow P_k^T p_i = 0, i=0, \dots, k-1. \quad \boxed{\text{f}}$$

* el residual es ortogonal a las direcciones anteriores.

* No necesitamos saber todas las direcciones anteriores
con P_{k+1} es suficiente -

P_k será conjugada al resto de las direcciones

$$P_k = -r_k + B_k P_{k+1}$$

B_k lo elegimos tal que P_{k+1} y P_k sean conjugados

$$0 = P_{k+1}^T A P_k = -P_{k+1}^T A r_k + B_k P_{k+1}^T A P_{k+1}$$

$$\Rightarrow B_k = \frac{P_{k+1}^T A r_k}{P_{k+1}^T A P_{k+1}} = \frac{r_k^T A P_{k+1}}{P_{k+1}^T A P_{k+1}}$$

Hibénous Algoritmo:

Paso 0:

$$r_0 = Ax_0 - b, P_0 = -r_0, k \leftarrow 0.$$

Mientras $r_k \neq 0$:

$$\alpha_k \leftarrow \frac{-r_k^T P_k}{P_k^T A P_k}$$

$$x_{k+1} \leftarrow x_k + \alpha_k P_k$$

$$r_{k+1} \leftarrow Ax_{k+1} - b$$

$$B_{k+1} \leftarrow \frac{r_{k+1}^T A P_k}{P_k^T A P_k}$$

$$P_{k+1} \leftarrow -r_{k+1} + B_{k+1} P_k$$

$$k \leftarrow k+1$$

Fin while.

$$r_i^T r_j = 0 \quad \forall i \neq j \quad \# P_k, r_k \quad \frac{P_k}{r_k} \in K(r_0, c) = \text{span}\{r_0, Ar_0, \dots, A^k r_0\}$$

$$r_{k+1} = r_k + \alpha_k A P_k$$

Teorema:

Supongamos que el késimo iterando no es x^* (solución del problema)

Entonces se cumple lo siguiente:

a) $r_i^T r_j = 0$ para $i = 0, 1, \dots, k-1$

① C ②) b) $\text{Span}\{r_0, r_1, \dots, r_k\} = \text{Span}\{r_0, Ar_0, \dots, A^k r_0\}$

③. = c) $\text{Span}\{p_0, p_1, \dots, p_k\} = \text{Span}\{r_0, Ar_0, \dots, A^k r_0\}$

④ d) $P_k^T A P_k = 0 \quad \forall i = 0, \dots, k-1$

Por lo tanto $\{x_k\}$ converge a x^* en al menos n pasos

Demarcación:

Se cumple para k , pd. para $k+1$.

Hic:

$$r_k \in \text{Span}\{r_0, Ar_0, \dots, A^k r_0\}$$

$$P_k \in \text{Span}\{r_0, Ar_0, \dots, A^k r_0\}$$

①

Sabemos que

$$A P_k \in \text{Span}\{Ar_0, \dots, A^{k+1} r_0\}$$

$$P_{k+1} \in \text{Span}\{r_0, \dots, A^{k+1} r_0\}$$

$$\text{Span}\{r_0, \dots, r_{k+1}\} \subset \text{Span}\{r_0, Ar_0, \dots, A^{k+1} r_0\}$$

$$A^{k+1}r_0 = A(A^kr_0) \in \text{Span}\{Ap_0, \dots, Ap_k\} \quad (2)$$

$$r_{k+1} = r_k + \lambda A p_k \Rightarrow Ap_k = \frac{r_{k+1} - r_k}{\lambda}.$$

$$\Rightarrow A^kr_0 \in \text{Span}\{r_0, \dots, r_{k+1}\}$$

$$(3) \quad \text{Span}\{p_0, \dots, p_{k+1}\} = \text{Span}\{p_0, \dots, p_k, r_{k+1}\} \quad \text{Algoritmo.}$$

$$= \text{Span}\{r_0, \dots, A^kr_0, r_{k+1}\} \quad \text{Hipótesis de Inducción.}$$

$$= \text{Span}\{r_0, r_1, \dots, r_k, r_{k+1}\} \quad (b)$$

$$= \text{Span}\{r_0, Ar_0, \dots, A^{k+1}r_0\}$$

$$(4) \quad P_k^T A p_i = -r_{k+1}^T A p_i + \underbrace{P_k P_k^T A p_i}_{\xrightarrow{\text{L}} \frac{r_{k+1}^T A p_k}{P_k^T A p_k}} = 0 \quad \text{si } i = k.$$

$\lambda \leq k-1$ p_0, \dots, p_k son conjugados ✓

$\xrightarrow{\text{Too close points}}$ $r_{k+1}^T p_i = 0 \quad \text{para } i = 0, \dots, k.$

$$Ap_i \in \text{Span}\{r_0, Ar_0, \dots, A^kr_0\} = \text{Span}\{Ar_0, A^2r_0, \dots, A^{k+1}r_0\} \subset \text{Span}\{p_0, \dots, p_{k+1}\}$$

$$P_{k+1}^T A p_i = 0 \quad \forall i = 0, \dots, k-1.$$

$$P_k^T A p_i = 0, \quad \text{con } i = 0, \dots, k-1.$$

$$\therefore P_{k+1}^T A p_k = 0$$

$$r_k^T r_i = 0 \quad \forall i=0, \dots, k-1.$$

Sabemos $r_k^T p_i = 0 \quad \forall i=0, \dots, k-1 \quad \forall i=1, \dots, n-1.$

$$p_i = -r_i + B_i p_{k+1}.$$

$$\Rightarrow r_i \in \text{Span}\{p_i, p_{k+1}\} \quad \forall i=1, \dots, k-1.$$

$$\Rightarrow r_k^T r_i = 0 \quad \forall i=1, \dots, k-1.$$

$$r_k^T r_0 = -r_k^T p_0 = 0$$

$$\therefore r_k^T r_i = 0 \quad \forall i=0, \dots, k-1.$$

Usando que $r_k^T p_i = 0 \quad i=0, \dots, k-1$ e $p_{k+1} = -r_{k+1} + B_{k+1} p_k$

$$\checkmark \quad d_k = \frac{r_k^T r_k}{P_k^T A P_k}$$

$$p_{k+1} = -r_{k+1} + B_{k+1} p_k$$

$$p_k = -r_k + B_k p_{k+1}$$

$$\checkmark \quad d_k A P_k = r_{k+1} - r_k$$

$$B_{k+1} = \frac{V_{k+1}^T A P_k}{P_k^T A P_k}$$

$$r_k^T p_i = 0 \quad \forall i=0, \dots, k-1$$

$$B_{k+1} = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$$

$$B_{k+1} = \frac{r_{k+1}^T \left[\frac{r_{k+1} - r_k}{d_k} \right]}{P_k^T A P_k} = \frac{\left[r_{k+1}^T r_{k+1} + 0 \right]}{P_k^T A P_k d_k}$$

$$= \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$$

Gradiente conjugado X

$r_i, r_j \rightarrow$ ortogonais

$$r_0 = \underline{A x_0 - b}$$

GC

Dado x_0 ,

$$r_0 \leftarrow Ax_0 - b$$

$$P_0 \leftarrow -r_0$$

$$k \leftarrow 0.$$

Mientras $r_k \neq 0$

$$\alpha_k \leftarrow \frac{r_k^T r_k}{P_k^T A P_k}$$



$$x_{k+1} \leftarrow x_k + \alpha_k P_k$$


$$r_{k+1} \leftarrow r_k + \alpha_k A P_k$$

$$P_{k+1} \leftarrow \frac{P_k^T r_{k+1}}{r_k^T r_k}$$

$$P_{k+1} \leftarrow -r_{k+1} + P_{k+1} P_k$$

$$k \leftarrow k+1$$

Fin.



git pull repo-clase main

work
!

git add

git commit -m "message"

git push origin main

* en github *

↳ Pull Request

Actualizar cambios Miguel -

work

mete al "lobby" los cambios.

guarda los cambios

sube los cambios al
repositorio Alumno_i

Convergencia GC.

los eigenvalores de la matriz A, determinan el desempeño del GC.

$$x_{k+1} = x_0 + \alpha_0 p_0 + \dots + \alpha_k p_k$$

$$= x_0 + \beta_0 r_0 + \gamma_1 A r_0 + \dots + \gamma_k A^k r_0 \text{ para constantes } \gamma_i$$

Polinomio $P_k^*(\cdot)$: polinomio de grado k. $\begin{pmatrix} \beta_0 \\ \gamma_1 \\ \vdots \\ \gamma_k \end{pmatrix}$

$$P_k^*(\lambda) = \beta_0 I + \beta_1 \lambda + \dots + \beta_k \lambda^k$$

$$x_{k+1} = x_0 + P_k^*(\lambda) \cdot r_0 \quad \|z\|_A^2 = z^T A z$$

$$\phi(x) = \frac{1}{2} x^T A x - b^T x$$

$$\frac{1}{2} \|x - x^*\|_A^2 = \frac{1}{2} (x - x^*)^T A (x - x^*) = \underbrace{\phi(x)}_{\uparrow} - \underbrace{\phi(x^*)}_{\downarrow}$$

$$\boxed{\left[\frac{1}{2} x^T A x - b^T x \right] - \frac{1}{2} x^T A x^* - b^T x^*}$$

Sabemos que x_{k+1} minimiza ϕ (y $\|x - x^*\|_A^2$) sobre el

$$\text{conjunto } x_0 + \text{Span}\{p_0 + p_1 + \dots + p_k\} = x_0 + \text{Span}\{r_0 + A r_0 + \dots + A^k r_0\}$$

P_k^* resuelve:

$$\min_{P_k^*} \|x_0 + P_k^*(\lambda) r_0 - x^*\|_A.$$

$$\text{y como } r_0 = Ax_0 \rightarrow b = A(x_0) - Ax^* = A(x_0 - x^*).$$

$$\begin{aligned} x_{k+1} - x^* &= x_0 - P_k^*(\lambda) r_0 - x^* \\ &= (I + P_k^*(\lambda) A)(x_0 - x^*). \end{aligned}$$

Sean $0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ eigen valores de A . y $\{v_i\}$ sus eigen vectores ortogonales

$$\Rightarrow A = \sum_{i=1}^n \lambda_i v_i v_i^T$$

$\{v_i\}$ genera \mathbb{R}^n

$$x_0 - x^* = \sum_{i=1}^n \xi_i v_i \text{ para coeficientes } \xi_i$$

$$P_k(A) v_i = P_k(\lambda_i) v_i, i=1, \dots, n.$$

$$x_{k+1} - x^* = \sum_{i=1}^n [1 + \lambda_i P_k(\lambda_i)] \xi_i v_i$$

$$\|x_{k+1} - x^*\|_A^2 = \min_{P_k} \sum_{i=1}^n \lambda_i [1 + \lambda_i P_k(\lambda_i)]^2 \xi_i^2$$

$$\|x_{k+1} - x^*\|_A^2 \leq \underbrace{\min_{P_k} \max_{1 \leq i \leq n} [1 + \lambda_i P_k(\lambda_i)]^2}_{= \min_{P_k} \max_{1 \leq i \leq n} [1 + \lambda_i P_k(\lambda_i)]^2} \underbrace{\|x_0 - x^*\|_A^2}_{\|x_0 - x^*\|_A^2}$$

$$\|x_0 - x^*\|_A^2 = \sum_{j=1}^n \lambda_j \xi_j^2$$

Tendremos una velocidad de convergencia del estimar

$$\min_{P_k} \max_{1 \leq i \leq n} [1 + \lambda_i P_k(\lambda_i)]^2$$

Teo: Si A tiene r eigenvalores diferentes, entonces GC termina en r iteraciones.

Probar: $\lambda_1, \dots, \lambda_n$ toman r valores diferentes $z_1 < z_2 < \dots < z_r$. definimos el polinomio

$$Q_r(\lambda) = \frac{(-1)^r}{z_1 \cdots z_r} (\lambda - z_1)(\lambda - z_2) \cdots (\lambda - z_r), \quad Q(\lambda_i) = 0, Q(0) = 1 \quad \forall i=1, \dots, n$$

$Q_r(\lambda) - 1$ es un polinomio grado r con raíz en $\lambda = 0$

Polinomio $\leftarrow \tilde{P}_{r-1}(\lambda) = \frac{(Q_r(\lambda) - 1)}{\lambda}$
grado $r-1$.

$$\begin{aligned} K = r-1 \\ 0 \leq \min_{P_{r-1}} \max_{1 \leq i \leq n} [1 + \lambda_i P_{r-1}(\lambda_i)]^2 &\leq \max_{1 \leq i \leq n} [1 + \lambda_i \tilde{P}_{r-1}(\lambda_i)]^2 \\ &= \max_{1 \leq i \leq n} Q_r^2(\lambda_i) = 0 \end{aligned}$$

~~$\neq 0$~~


$$\|x_r - x^*\|_A^2 = 0 \Rightarrow x_r = x^*$$

Si A tiene eigenvalores $\lambda_1 \leq \dots \leq \lambda_n$ tenemos que:

$$\|x_{k+1} - x^*\|_A^2 \leq \left(\frac{\lambda_{n-k} - \lambda_1}{\lambda_{n-k} + \lambda_1} \right) \|x_k - x^*\|_A^2$$

Además si tomamos el número de cond $K(A) = \|A\|_2 \|A^{-1}\|_c = \frac{\lambda_n}{\lambda_1}$
se puede mostrar que:

$$\|x_k - x^*\|_A \leq 2 \left(\frac{\sqrt{K(A)} - 1}{\sqrt{K(A)} + 1} \right) \|x_0 - x^*\|_A$$



Las distribuciones de los eigenvalores
nos dicen cómo se comportará el algoritmo

Precondicionamiento

Podemos acelerar el GC. Ajustando la distribución de los eigenvalores. El precondicionamiento es un cambio de variable vía una matriz no singular C .

$$\hat{x} = Cx -$$

$$\hat{\phi}(x) = \frac{1}{2} \hat{x}^T (\bar{C}^T A \bar{C}) \hat{x} - (\bar{C}^T b)^T \hat{x}$$

$$\Rightarrow \bar{C}^T A \bar{C} \hat{x} = \bar{C}^T b.$$

Ahora nos importan los eigenvalores de $\bar{C}^T A \bar{C}$

∴ La elección de C es crucial.

dejir C tal que el numero de condición se
auche. o tal que se agrupen eigenvalores.

$$M = \underline{C^T C}.$$

Algoritmo Precondicionado Gradiente Conjugado

dado x_0 , Precondicionador M , A , b .

$$r_0 \leftarrow Ax_0 - b$$

Resolver $My_0 = r_0$ para y_0 .

$$p_0 \leftarrow -y_0, k \leftarrow 0.$$

Mientras $r_{k+1} \neq 0$

$$\alpha_k \leftarrow \frac{r_k^T y_k}{p_k^T A p_k}$$

$$x_{k+1} \leftarrow x_k + \alpha_k p_k$$

$$r_{k+1} \leftarrow r_k + \alpha_k A p_k$$

Resuelve $My_{k+1} = r_{k+1}$ para y_{k+1}

$$\beta_{k+1} \leftarrow \frac{r_{k+1}^T y_k}{r_k^T y_k}$$

$$p_{k+1} \leftarrow -y_{k+1} + \beta_{k+1} p_k$$

$$k \leftarrow k+1$$

fin.

En lugar que $r_i^T r_j = 0$
tenemos $r_i^T M r_j = 0$. fij.

$$My = r.$$